多路词法检索的排名融合

RRF 的原理、适用条件与实证评估

信息检索原理　论文阅读汇报

研究问题：不同排序怎样融合

- BM25 与 TF-IDF 对同一查询产生不同排名。
- 原始分数的范围、分布和含义不同，直接相加缺少可比性。
- RRF 只使用排名，让多个检索器共同提供证据。

待检验的问题：排名的一致支持，能否抵消单路检索的错误？

RRF：排名倒数的加和

$$S_{\mathrm{RRF}}(d) = \sum_{j=1}^{m} \frac{\mathbf{1}[d \in L_j]}{c + r_j(d)}$$

- L_j 为第 j 路候选列表，排名 r_j 从 1 开始。
- 未进入某路列表的文献，该路贡献为 0。
- 原论文固定 $c = 60$，缓和个别检索器的极高排名。

只保留顺序信息，也同时舍弃了原始分数的差距。

数值例子：两路共同靠前的文献

文献	排名 1	排名 2	RRF 分数（$c = 60$）
A	1	20	0.02889
B	2	2	**0.03226**
C	20	1	0.02889

B 在两路均靠前，融合后超过只在一路排名第一的 A、C。

原论文的证据与适用边界

- 在论文测试的 TREC 排序与 LETOR 设置中，RRF 表现出较强的融合效果。
- 无需相关性训练标签，也无需统一各路分数尺度。
- 融合依赖输入排序的质量和互补性。
- 候选列表之外的相关文献无法通过融合找回。

需要另做实验：词法方法高度相关时，收益是否仍然存在？

后续研究：RRF 的参数与分数融合

$$S_{\mathrm{CC}}(d) = \alpha\,\widetilde{s}_1(d) + (1-\alpha)\,\widetilde{s}_2(d)$$

- Bruch 等研究词法与语义检索的融合，比较 RRF 与凸组合 CC。
- 该研究发现 RRF 对参数存在敏感性，调优 CC 在其设置下更好。
- 因此 $c = 60$ 是可复现的默认值，不能当作所有任务的最优值。

BEIR 与 SciFact 的检索任务

- BEIR 提供多领域检索数据、相关性标注与统一评测接口。
- SciFact 查询为科学声明，目标为包含证据的文献摘要。
- 官方预处理包：5,183 篇文献，300 个测试查询。
- 本项目只评估文献检索，不评估支持或反驳分类。

课程 Project：比较互补性与代价

- **单路**：BM25、word TF-IDF、char TF-IDF。
- **融合**：BM25+word、BM25+char、三路 RRF。
- **参数对照**：固定 $c = 60$ 与开发集调优的加权 RRF、CC。
- **同时记录排序质量、候选召回与 CPU 查询耗时。**

假设：字符特征可能提供额外召回，也可能增加噪声和耗时。

评测与信息泄漏防范

- nDCG@10 衡量前列排序，MRR@10 关注首个相关结果。
- Recall@100 衡量候选覆盖，全部查询做宏平均。
- 仅用 train 查询调参数，test 标签只进入最终评估。
- 对查询差值做配对 bootstrap，区分平均提升与统计不确定性。

阅读结论与参考文献

RRF 提供简单、便于复现的融合基线。

其有效性需要结合候选互补性、参数和额外开销评估。

1. Cormack, Clarke, Büttcher. RRF. SIGIR 2009. doi:10.1145/1571941.1572114
2. Bruch, Gai, Ingber. An Analysis of Fusion Functions for Hybrid Retrieval. TOIS 2023. arXiv:2210.11934
3. Thakur et al. BEIR. NeurIPS Datasets and Benchmarks 2021. arXiv:2104.08663