排序融合何时有效？
互惠排名融合的原理、反例与可复现评价设计

《信息检索原理》第九周论文阅读报告

Course Project
信息检索原理课程
Beijing, China

ABSTRACT

多个检索器给出不同答案时，融合排序既可能利用互补信息，也可能重复放大同一种错误。本文围绕互惠排名融合（Reciprocal Rank Fusion，RRF）的原始论文展开批判性阅读，并结合现代混合检索融合分析与 BEIR 评价框架，讨论排名、分数、候选集合和评价协议之间的关系。本文将文献证据与自主推导分开：对文献仅概述其可核实结论；通过自行构造的小型排序、参数翻转、分数缩放和重复投票案例，解释 RRF 的行为与失败条件；进一步给出不依赖测试集调参的课程项目方案。分析表明，RRF 的工程吸引力来自其对分数尺度的独立性，而不是对检索器质量、候选深度或参数选择的独立性。合理评价应同时固定输入预算，报告单路基线、相关性、召回上界和查询级差异。本文不将设计中的项目实验作为已完成结果。

KEYWORDS

信息检索，排序融合，RRF，混合检索，候选截断，可复现评价

1 阅读问题与证据边界

1.1 从一个查询出发

考虑查询“向量检索中如何融合关键词匹配”。一个词项检索器可能优先返回标题含有“向量”“融合”的文档，另一个语义检索器可能返回没有这些原词、却讨论混合搜索的文章。两者都具有合理依据。把两个列表拼接起来会遇到重复文档；把原始分数相加又默认了分数单位可以比较。排序融合因此不是简单的结果合并，而是在多个不完全一致的相关性证据之间作出决策。

本文关注三个问题。第一，RRF 究竟保留了什么、舍弃了什么？第二，当一种方法在经典数据上表现稳定时，我们能把这个经验推广到什么范围？第三，课程项目如何区分真正的融合收益与候选增加、参数搜索或重复检索造成的表面收益？这三个问题把算法公式、实验证据和实现细节连接起来。

1.2 三篇材料的分工

主论文为 Cormack 等人的 SIGIR 2009 短文 [2]，共两页。它提供 RRF 的公式、经典实验和简洁的工程论证。补充阅读为 Bruch 等人的融合函数分析 [1]，本文采用 2023 年修订的 arXiv 版本，避免把预印本误写成 SIGIR 会议论文。第三篇 BEIR 论文 [3] 提供跨任务评价的背景，而不提供本文所提项目的实验结果。

本文表格中的手算排序、证明和项目方案均为自主分析。只有明确标为“文献证据”的数值来自原论文。下文的示例文档 A、B、C 并非真实语料中的检索结果；它们用于检验公式的性质。讨论中出现的潜在收益、失败情形和假设，也不等同于在某个真实数据集上已经验证的结论。

2 融合前需要明确的检索表示

2.1 词项匹配与向量匹配

TF–IDF 可将查询与文档表示为词项权重向量。一种常见定义为

$$w_{t,d} = \mathrm{tf}(t,d)\log\frac{N}{\mathrm{df}(t)}, \qquad s_T(q,d) = \frac{\boldsymbol{w}_q^\top \boldsymbol{w}_d}{\|\boldsymbol{w}_q\|\|\boldsymbol{w}_d\|}. \tag{1}$$

实际实现往往使用平滑 IDF、次线性 TF 或不同归一化。公式中的选择并非无关紧要：若文档长度处理不同，长文档可能获得不同的排序优势。因此，“TF–IDF 基线”应连同分词、IDF 和归一化定义一起给出。

BM25 同样使用词项证据，但通过词频饱和与长度归一化调整贡献。为统一讨论，本文采用正值 IDF 的一种常见写法：

$$s_B(q,d) = \sum_{t\in q}\log\left(1+\frac{N-n_t+0.5}{n_t+0.5}\right)\frac{f_{t,d}(k_1+1)}{f_{t,d}+k_1(1-b+b|d|/\bar{l})}. \tag{2}$$

其中 k_1 控制词频增长的饱和速度，b 控制长度影响。这里忽略查询词频因子，是为了突出文档端机制；项目若采用其他变体，应记录差异。TF–IDF 和 BM25 并非彼此独立的相关性来源，它们通常共享分词、词项统计和字面匹配偏好。

稠密检索可写为 $s_D(q,d) = \boldsymbol{e}_q^\top \boldsymbol{e}_d$；当向量单位归一化时等于余弦相似度。它与词项方法的差异在于表示空间及训练目标，而不是名字中带有“向量”就必然更准确。对术语、编号与罕见实体的查询，字面匹配仍可能提供重要证据；反过来，向量模型可能弥补同义表达引起的词汇不匹配。

2.2 为何原始分数不能直接比较

假设系统一给 A、B 的分数分别为 9 和 8，系统二分别给 0.2 和 0.9。相加后 A 得 9.2，B 得 8.9。现在只把系统二的计分单位乘 100：单路次序不变，融合却变为 A 得 29、B 得 98。直接加分实际上把计分单位当成了系统权重。

这不意味着分数毫无价值。分数间隔可能反映模型对两个候选的区分强度。问题在于必须先说明分数的语义、尺度和归一化，再讨论如何利用它。RRF 选择绕开计分单位，代价则是只保留顺序信息。这是一项信息取舍，而不是免费获得的稳健性。

3 RRF 公式及其可证明性质

3.1 全排列定义与有限列表实现

主论文在共同文档集 D 上定义多个排名 r_i，排名从 1 开始：

$$\mathrm{RRF}_k(d) = \sum_{i=1}^{m}\frac{1}{k+r_i(d)}, \qquad k \geq 0. \tag{3}$$

分数越大，融合名次越靠前。工程上通常只有每路前 L 个文档，不能假装知道列表之外的完整名次。本文约定候选集 $C =$

$\bigcup_i C_i$，并定义

$$S_k(d) = \sum_{i=1}^{m} \frac{\mathbf{1}[d \in C_i]}{k + r_i(d)}, \quad d \in C. \tag{4}$$

这是本文的有限列表实现约定；缺失项贡献 0，不能将其误写成原论文全排列定义本身。缺失也不等于已经判定不相关，它只说明该检索器没有在给定预算内返回该文档。

3.2 单调性、界与不变量

若某文档在所有系统中的名次都不变或上升，并至少在一路严格上升，则在候选出现情况不变时，其 RRF 分数严格增加。这直接来自 $1/(k+r)$ 对 r 严格递减。对 m 路有限列表还有

$$0 < S_k(d) \le \frac{m}{k+1}, \quad d \in C. \tag{5}$$

这个界说明 RRF 分数受路数影响，因而跨配置比较原始融合分数通常没有意义。比较的是文档次序与评价指标，不是“0.04 比 0.03 更相关”。

对任意严格递增函数 g_i，用 $g_i(s_i)$ 替换第 i 路原始分数不会改变单路次序，因而不改变 RRF。这解释了它的尺度不变性。它却不具备表示不变性：换分词器、换索引、改变候选截断或引入新的平分规则，都可能改变排名，进而改变融合。

3.3 头部权重与参数含义

同一路中第 r 名和第 $r+1$ 名贡献的差为

$$\Delta_r = \frac{1}{(k+r)(k+r+1)}. \tag{6}$$

随着 r 变大，局部位置差异越来越弱；随着 k 增大，所有位置之间的差也变小。第 1 名相对第 r 名的贡献比为 $(k+r)/(k+1)$。当 $k=0$ 时，第 1 名对第 10 名的比为 10；当 $k=60$ 时则为 $70/61$，约 1.148。平滑常数因此不是展示层的细节，而是明确改变“单路特别靠前”和“多路共同出现”之间的平衡。

4 可核验的手算案例与反例

4.1 两路互补排序

构造两路各含三个文档的列表，如表1。设 $k=60$，A 的得分为 $1/61+1/63$，B 为 $2/62$，C 为 $1/63$，D 为 $1/61$。此例中特别值

Table 1: 本文构造的有限列表案例，不是真实实验结果。

文档	路一名次	路二名次	RRF 分数	融合名次
A	1	3	0.032266	1
B	2	2	0.032258	2
C	3	缺失	0.015873	4
D	缺失	1	0.016393	3

得解释的是 A 和 B：两者的名次和都是 4，RRF 却给 A 略高的分数。令 $f(x)=1/(k+x)$，则 $f''(x)=2/(k+x)^3>0$，所以 f 为凸函数；相同平均名次下，不平衡的 $(1,3)$ 会比均衡的 $(2,2)$ 获得略高贡献。RRF 不是简单平均名次，也不总是偏好“每路都稳定靠前”的候选。

差异只有约 8×10^{-6}。若程序先四舍五入到四位小数再排序，会把真实的严格次序变成平分。因此实现时应保留完整浮点值，输出时再格式化，并对真正的同分采用确定性规则，例如文档 ID 升序。这个细节可以通过单元测试核对，无需真实语料。

4.2 同一对候选随参数翻转

构造 X 的两路名次为 $(1,100)$，Y 为 $(10,10)$。比较

$$S_k(X) = \frac{1}{k+1} + \frac{1}{k+100}, \qquad S_k(Y) = \frac{2}{k+10}. \tag{7}$$

通分后，$S_k(X)-S_k(Y)$ 的符号等于 $810-81k$ 的符号。因此 $k<10$ 时 X 领先，$k=10$ 时相等，$k>10$ 时 Y 领先。这个精确反例不声称真实集合必然如此，却足以否定“改变 k 不会影响排序”的无条件说法。

两份列表中的其余名次可以由不同填充文档占据，故这个构造与完整排名相容。如果只截取前 50 名，X 在第二路不再出现，分数差又发生变化。参数作用与候选深度因而不能分别孤立解释：k 作用于可见名次，而深度决定哪些证据可见。

4.3 候选出现频次与大参数极限

对有限名次范围，当 k 足够大时，可用展开式

$$\frac{1}{k+r} = \frac{1}{k} - \frac{r}{k^2} + O(k^{-3}) \tag{8}$$

得到

$$S_k(d) = \frac{c(d)}{k} - \frac{\sum_{i:d\in C_i} r_i(d)}{k^2} + O(k^{-3}), \tag{9}$$

其中 $c(d)$ 为返回 d 的系统数量。有限列表下，大 k 首先偏好出现次数，然后才区分名次和。若所有系统都给出同一全集的完整排列，所有文档的 $c(d)=m$ 相同，第一项不再区分文档；这时近似比较平均名次。区分这两种输入设定，才能准确解释所谓“共识”。

4.4 复制检索器为何不是增加知识

设原来有两路分数贡献 $a(d)$ 与 $b(d)$，结果为 $a(d)+b(d)$。若把第一路原样复制两次，结果变为 $3a(d)+b(d)$。数据与算法都没有新增独立证据，但系统一的相对权重已经变成三倍。

因此，检索器数量不应被等同于信息来源数量。把 BM25 的几个极相近参数版本全部加入，与加入一个能找到不同相关文档的检索器，机制不同。项目中应把“相同列表重复加入”作为负控制：如果重复使结果改善，能说明特定权重可能有益，却不能说明获得了新互补信息。

5 与其他融合规则的比较

5.1 Borda 式排序、Condorcet 与 CombMNZ

按名次求和的 Borda 式方法可以写为 $S_{\mathrm{rank}}(d) = -\sum_i r_i(d)$，但有限列表的缺失名次需要额外约定。它对头部与尾部的一次位置变化给予同样差值。RRF 则用非线性递减函数强化头部，二者不能仅凭“都只用名次”而视为等价。

Condorcet 融合通过多系统对候选对的偏好来决定次序。它具有投票式解释，但多数候选对上的偏好不保证存在一个无环的全局顺序。例如三路分别偏好 A>B>C、B>C>A、C>A>B，则多数票形成 A>B、B>C、C>A 的环。具体实现必须处理循环与平票。RRF 把各路证据转换为可加分数，避开这一排序关系的不传递性问题，但并未因此取得相关性最优保证。

CombMNZ 可概括为返回次数乘以分数和：

$$S_{\mathrm{MNZ}}(d) = c(d) \sum_{i:d\in C_i} \widetilde{s_i}(d). \tag{10}$$

这里用 $\widetilde{s}_i$ 强调项目需要明确归一化。该规则显式奖励多路命中，同时仍使用分数间距；若计分单位不一致，乘上命中次数不会自动解决尺度问题。对于全为 0、常数分数或负分数的输入，还需说明“命中”的判断依据，不能把“分数非零”默认为“确实返回”。

5.2 凸组合及归一化

两路分数的凸组合（CC）为

$$S_\alpha(d) = \alpha \widetilde{s}_1(d) + (1-\alpha)\widetilde{s}_2(d), \quad 0 \le \alpha \le 1. \tag{11}$$

常见 min–max 归一化为

$$\widetilde{s}_i(d) = \frac{s_i(d) - s_i^{\min}}{s_i^{\max} - s_i^{\min}}. \tag{12}$$

如果最大最小值相等，应采用预先规定的退化处理，例如该路对当前查询贡献 0，而不是除以 0。归一化范围是在全库、候选并集还是单路返回集合上计算，也必须固定。极端高分会压缩其他候选的分数差，所以归一化不仅是代码中的一行变换。

考虑两路正仿射变换 $s_i' = a_i s_i + b_i$，其中 $a_i > 0$ 且 b_i 对当前查询的所有候选相同。变换后的 CC 为

$$S'_\beta = \beta a_1 s_1 + (1-\beta) a_2 s_2 + \text{常数}. \tag{13}$$

若希望其与原来的权重 α 产生相同次序，只需满足

$$\frac{\beta a_1}{(1-\beta)a_2} = \frac{\alpha}{1-\alpha}, \qquad \beta = \frac{\alpha a_2}{(1-\alpha)a_1 + \alpha a_2}. \tag{14}$$

这说明某些尺度变化可以通过权重变换抵消。但如果 a_1, a_2 随查询变化，一个固定的全局 β 不一定同时适用于所有查询。另一个限制是候选缺失：对缺失项直接补 0，可能破坏“每个候选加同一常数”的条件。讨论归一化等价时必须把假设写清。

5.3 分数间距确实可能影响合理决策

自行构造两个候选 A、B，系统一始终将 A 排第一、B 排第二。情形甲的系统一归一化分数为 $(1, 0.99)$，情形乙为 $(1, 0)$；系统二在两种情形均为 $(0, 1)$。取 $\alpha = 0.6$，甲中 A 得 0.6、B 得 0.994，乙中 A 得 0.6、B 得 0.4。CC 在两种情形给出不同答案，而 RRF 看到的排名完全相同，不能区分它们。

这个例子不证明 CC 必然更好，因为分数间距也可能失准。它只说明两种规则可利用的信息不同：RRF 不受任意计分尺度的影响，却也无法响应分数中可能存在的强置信度证据。选择规则需要判断这些间距是否可信，以及是否有独立验证查询可以学习权重。

6 原论文的证据应怎样解读

6.1 简短的文献证据摘要

原论文固定 $k = 60$ 用于后续验证；先导表格中 $k = 80$ 的 MAP 为 0.2147，$k = 60$ 为 0.2145。TREC3 中 CombMNZ 为 0.4381，高于 RRF 的 0.4350；TREC9 的人工参与最佳系统也高于 RRF。LETOR3 中 RRF 的 MAP 为 0.6051，CombMNZ 为 0.6107，二者差异未达显著（$p = 0.2$）[2]。这些数字是文献结果，并非本文重现实验。

这些证据支持将 RRF 视为值得保留的简洁基线，却不支持“无需检验就优于任何单路或融合方法”。读论文时，标题、摘要和正文应相互约束：一句范围很宽的总结，必须回到实际比较对象、数据和例外中理解。

6.2 从经验结论到条件性结论

“无监督融合”不表示整条检索流水线不需要训练。若输入排名来自监督学习模型，RRF 只是在融合阶段无需额外拟合。报告一个免训练融合方法时，应分别描述检索器训练、融合权重学习和测试域适配，避免把不同阶段混为一谈。

“最佳单路”也可能具有两种含义：在独立验证集上选定的部署基线，或事后在测试集合上挑出的最优值。后者适合作为参照上界，但不应作为一个声称无需测试标签就可选择的系统。项目应同时报告每一路，并写清最佳基线如何选择。

单一平均指标可能隐藏失败群体。假设三个查询的基线 AP 为 $(1, 0, 0)$，融合后为 $(0.5, 0.3, 0.3)$，平均值上升，但原本答对的查询明显退化。真实用户若集中在这类查询，宏平均收益就不足以解释部署价值。因此，除了均值，还应检查逐查询差值、胜负数量和典型失败查询。

7 现代材料带来的修正

7.1 融合函数分析：无需训练不等于无需参数

Bruch 等人在词项与语义检索融合中研究 CC 与 RRF，报告 RRF 对参数的敏感性，并在其研究设置中观察到调参 CC 的优势；他们还讨论了线性归一化与可等价排序的权重变换，以及少量标注查询学习融合权重的作用 [1]。这是对特定研究设置的实证与理论分析，不能被改写成“CC 在所有任务中都优于 RRF”。

对课程项目而言，阅读两篇文献的价值不是给 2009 年的方法判定过时，而是学习区分三种情境：没有目标域标注时，默认 RRF 可作为容易启动的方案；有验证数据时，应允许 CC 和 RRF 在相同预算下调参；发生域迁移时，源域最优参数是否仍有效需要单独测试。把不同情境合在一个结论里，往往会把数据条件造成的差异归因于公式本身。

理论分析也提示一个报告习惯：指出结论成立的变量范围。式中的秩常数、候选深度与输出深度分别起不同作用，通常都被写成字母 k 会引起混淆。本文将 RRF 平滑常数记为 k，单路候选深度记为 L，最终评价截止位置记为 K。复现实验的配置文件应沿用这种区分。

7.2 BEIR：跨域评价的必要性

BEIR 由多个不同领域与任务的数据集组成，原论文使用 18 个公开数据集评价多种检索架构，显示简单词项基线仍值得重视，效果、计算成本与跨域能力也并不总是同步改善 [3]。本文不借用其排行榜来声称课程项目已经具备跨域结论，而是把异构任务视为检查泛化假设的动机。

在一个小型课程项目中，选择一个公开子集完成闭环，比罗列很多没有运行的数据集更可核验。若资源允许，再增加任务差异明显的第二个集合进行外部验证。所有集合的逐查询评价均须使用各自的 qrels；不可把某个集合的调参结果与另一个集合的测试标签混合使用。

8 候选截断、相关性与评价陷阱

8.1 任何融合都受候选集上界约束

设 G_q 为查询 q 的已知相关文档集合，C_q 为候选并集，$F_q^K \subseteq C_q$ 为最终前 K 结果，则

$$\text{Recall}@K(q) = \frac{|F_q^K \cap G_q|}{|G_q|} \le \frac{|C_q \cap G_q|}{|G_q|}. \tag{15}$$

右侧是候选集合能达到的召回上限。若相关文档从未被任何一路召回，再精巧的排序公式也无法把它放进结果。评价时应先

问是候选发现不足，还是并集内排序失败；两者需要的改进不同。

增大 L 使候选并集单调扩大，但有限列表 RRF 的最终效果不必单调改善：更多候选会竞争头部位置，既有候选也可能在另一路新获得一项贡献。公平实验应分别比较“同每路深度”和“同总候选预算”两种设置，说明融合是否额外用了更多检索计算。

8.2 重叠不等于互补，也不等于无用

可用 Jaccard 系数描述返回集合的重叠：

$$J(C_1, C_2) = \frac{|C_1 \cap C_2|}{|C_1 \cup C_2|}. \tag{16}$$

低重叠并不保证收益，因为两路可能只是各自找到不同的不相关文档。真正有用的互补可以通过独有相关文档数考察，例如 $|(C_2 \setminus C_1) \cap G_q|$。高重叠也不意味着一路多余，因为两路可能在同一候选集内提供不同次序，有助于重排。

次序相关性可以在共同候选上计算，但必须说明缺失项处理方式。只在交集上计算相关性，会忽略恰好最能体现召回差异的部分；给所有缺失项同一个末位，也会制造大量平分。项目中将集合重叠、独有相关文档与最终效果分开报告，比把它们压成一个“多样性分数”更容易解释。

8.3 指标的含义与边界

对二值相关性，平均精确率可写为

$$\mathrm{AP}(q) = \frac{1}{|G_q|} \sum_{j=1}^{n} P@j(q)\ \mathrm{Rel}_q(j), \qquad \mathrm{MAP} = \frac{1}{|Q|} \sum_{q} \mathrm{AP}(q). \tag{17}$$

如果只保存前 n 个结果，未返回的相关项贡献 0。若按 cutoff 报告 AP，应把该 cutoff 明确写出。MAP 对所有查询等权，不能与把查询的相关文档混在一起计算的微平均混用。

分级相关性常用

$$\mathrm{DCG}@K(q) = \sum_{j=1}^{K} \frac{2^{g_q(j)} - 1}{\log_2(j+1)}, \quad \mathrm{nDCG}@K = \frac{\mathrm{DCG}@K}{\mathrm{IDCG}@K}. \tag{18}$$

应预先规定无相关项查询或 IDCG 为 0 时的处理。MRR 则只看首个相关结果的位置倒数；它不是 RRF 的缩写变体，也不能反映多个相关文档的完整覆盖。本文建议头部 nDCG、Recall 和 MAP 共同报告，避免一个指标包办所有质量维度。

8.4 不完全标注与统计解释

qrels 是已获得的相关性判断，而非完备真值。通常把未标注文档按不相关计分，便于统一计算，但新的召回器找到未判断文档时可能被低估。课程报告应保留这个限制，不擅自修改官方 qrels 来让某种方法显得更好。个例分析可另外记录“未判断”，与已确认不相关区分。

对两个系统，令 $\delta_q = M_q(A) - M_q(B)$，先报告平均差值和查询级分布，再考虑统计检验。一个透明的方案是按查询配对重采样 bootstrap，报告均值差的置信区间、重复次数和随机种子。若同时搜索很多参数，测试集上最好的差值会有选择偏差；因此参数选择在验证集完成，测试集仅做一次最终比较。置信区间跨 0 不表示两个系统完全相同，只表示现有样本不足以排除零差异。

9 课程项目：把阅读问题变为可执行协议

9.1 研究假设与最小闭环

项目可命名为“公开语料上的多路排序融合及敏感性分析”。最小版本保留 TF–IDF、BM25 两路，比较单路、RRF 和归一化 CC；可选加入一个公开稠密检索器形成更有差异的来源。若没有运行稠密模型，不应把词项两路的结果包装成已经完成的语义混合检索。

拟检验的假设为：RRF 能否在固定检索预算下改善头部排序；收益是否与独有相关候选有关；默认常数 60 与验证集选择的常数是否有稳定差异；归一化 CC 是否通过少量验证查询获得收益。这些均为待检验假设，而不是报告预设结论。负结果同样可以回答问题，例如词项两路过于相似，融合没有改善，就是有解释价值的发现。

9.2 数据、划分与泄漏防护

输入由 corpus、queries 和 qrels 三部分组成，采用稳定文档 ID 与查询 ID 连接。语料预处理应确定 Unicode 规范化、大小写、标点、停用词与词干化的策略；并保留文档标题是否拼接正文的信息。所有检索器使用同一可检索文档集合，避免某一路少建了文档而造成伪差异。

若集合提供官方训练、验证、测试划分，优先遵循。若没有，则在查看测试表现前按固定种子划分有标注查询，并保存 ID 列表。小数据上可采用验证折选择参数，保留一个最终测试部分。不能用测试集最优 k 宣称“默认 RRF 效果”，也不能先挑选融合改善最多的查询再展示整体结论。

9.3 参数与对照实验

表2给出计划中的参数轴。网格规模应受运行预算限制，所有候选配置与选择规则提前保存。参数之间可能有相互作用，首先固定其他参数做一维曲线，再在独立验证集选择最终配置，减少解释上的自由度。

Table 2: 建议实验协议；本表仅为计划，不包含完成结果。

轴或对照	预先规定的检查方式
单路基线	TF–IDF、BM25；可选稠密检索
RRF 常数	$k \in \{0, 10, 20, 60, 100\}$；60 单独列为默认
候选深度	$L \in \{10, 50, 100\}$，输出 K 固定
CC 权重	$\alpha \in \{0, 0.1, \ldots, 1\}$，仅验证集选择
控制变量	同语料、同查询、同 qrels、同分词版本
负控制	复制一路列表；改变输出格式不改变分数
结果呈现	nDCG@10、Recall@100、MAP 与逐查询差值

同一参数网格在不同数据集上是否需要重新调参，应作为实验设置的一部分。如果为了目标域性能重新选择参数，就不能再把该结果称为完全零样本。端点 $\alpha = 0, 1$ 也应保留，防止融合网格排除了单路而迫使系统“必须融合”。

9.4 实现、核对与运行产物

一个清晰的实现流程为：读入语料并建立索引；每路对每个查询输出带 docid、rank、score 的运行文件；对相同 query 连接候选；计算融合；用同一评价器运行；导出逐查询与汇总表。将检索和融合分离后，参数实验可以复用已有运行文件，不必每次重建索引。

RRF 逐路遍历返回项，用字典保存文档 ID 与累加分数。累加的时间复杂度为 $O(mL)$。若对候选并集完全排序，整体时间成本为

$$T_{\text{fusion}} = O\big(mL + |C|\log|C|\big). \tag{19}$$

这些仅是融合成本，不含检索、编码或索引构建。报告应区分冷启动、索引构建和查询阶段。把缓存后的查询时间与全流程时间混比，会夸大效率差异。

最小正确性核对应包括：排名从 1 开始；同一路重复 docid 不重复计票；缺失不贡献；同分次序可复现；手算表1匹配；复制一路等价于增加对应权重；在所有路相同且文档集合一致时，融合次序不变。评价器另需用一个人工标注的小集合检查 AP 与 nDCG，避免把实现错误当成算法结论。

应保存的产物包括配置、环境版本、输入下载来源、数据校验信息、固定划分、单路 run 文件、融合 run 文件、逐查询指标、汇总结果和运行日志。结果表中的空白只能解释为未运行，不能填入原论文数值作为自己的复现分数。若加入稠密模型，还需记录模型名称与版本、向量归一化、相似度和近邻搜索是否精确。

9.5 结果解释的优先顺序

完成实验后先检查单路与候选召回上界，再比较融合质量，随后解释参数和失败查询。若融合未提升，应先排除索引、ID 对齐和评价错误，再检查两路相关性过高或某一路质量太差。若融合提升，则检查是否只因候选增多，是否在固定预算下仍成立，是否对少数查询损伤严重。

展示时可选一个改善查询与一个退化查询，列出原始名次、融合贡献、相关性标签及文档片段。例子应来自预先明确的选择标准，例如最大正差和最大负差，避免只挑支持观点的案例。最终结论应写成“在指定数据、预算和指标下观察到什么”，而不是把某个默认参数升级为通用规律。

10 进一步分析：从排序行为到决策代价

10.1 文档级加分不能替代查询级可靠性判断

RRF 对所有查询采用相同的计分函数。一条查询可能是精确编号，另一条可能是概念描述；两类查询对词项与语义证据的依赖可能不同。如果对某类查询，系统一的排名更可靠，等权融合就存在把可靠结果拉向不可靠结果的风险。这个问题不能只靠增加一个全局平滑常数解决，因为常数同时作用于所有候选和查询。

一个可分析的扩展是加权 RRF：

$$S_{k,w}(q,d) = \sum_i w_i(q)\frac{\mathbf{1}[d \in C_i(q)]}{k + r_i(q,d)}, \quad w_i(q) \ge 0. \tag{20}$$

若所有权重相同，则退化为等权版本；将权重统一乘正常数不会改变排序，因此可令 $\sum_i w_i(q) = 1$。需要强调的是，加权版本并非原始 RRF 不调参基线：如果 $w_i(q)$ 依赖标签学习，就应计算训练样本与特征获取成本，并与一个只学习全局权重的简单对照比较。

查询自适应并不应成为课程项目的必要任务。先验证全局等权、全局可学习权重的差异，已经能够回答“性能限制来自证据本身还是等权假设”的一部分。若直接引入复杂门控网络，参数、训练与检索表示的变化会叠在一起，难以归因。

10.2 弱检索器能否被自动忽略

设原有系统对 A、B 的融合分差为 $\gamma = S(A) - S(B) > 0$，新增一路的贡献差为

$$\eta = \frac{\mathbf{1}[A \in C_{m+1}]}{k + r_{m+1}(A)} - \frac{\mathbf{1}[B \in C_{m+1}]}{k + r_{m+1}(B)}. \tag{21}$$

加入后若 $\gamma + \eta < 0$，A、B 的次序就翻转。由于 $|\eta| \le 1/(k+1)$，可以得到一个充分条件：若 $\gamma > 1/(k+1)$，单路新增证据无法反转这对候选。然而多数真实头部候选的差距可能远小于这个界，是否安全不能仅凭系统数量判断。

若新增一路只给 B 高排名而完全漏掉 A，最大负扰动就接近 $-1/(k+1)$。RRF 不知道这一路很弱；“它只用名次”也意味着“它无法直接利用分数是否经过校准来识别弱源”。这一分析提示应同时评价每路单独效果、移除一路的消融与加入噪声路的压力测试。只展示最佳融合组合，无法判断方法对低质量来源是否稳健。

10.3 并集、交集与推荐解释不同

对两个有限候选列表，选择并集允许任一路独有的文档进入最终结果，选择交集则要求双方共同返回。交集可以减少候选数量，却会把互补召回的潜在价值直接删除。若相关文档只出现在一路，交集上的任何排序都无法保留它。因此两种候选策略对应不同决策，不能在比较两种融合公式时偷偷同时更改候选策略。

另一方面，多路共同命中只能提供一种一致性证据，并不等于独立验证。一份错误文档若因共同分词或热门词而被所有词项检索器返回，RRF 仍可能给它很高分。系统对外展示“被三种检索器支持”时，应避免把算法数量包装成三个独立可信来源。若还要生成答案，文档事实的可核验性属于另一层问题，排序分数本身并不能完成事实验证。

10.4 平分排名与确定性处理

单路中经常出现相同分数，尤其是短查询、短文本或离散计分的情况。可以给平分文档分配平均秩，也可以按稳定文档 ID 打破平分。两者对 RRF 不完全等价，因为倒数函数为非线性。若 A、B 共享位置 1 与 2，平均秩方案给两者 $1/(k+1.5)$；稳定 ID 方案则分别给 $1/(k+1)$ 与 $1/(k+2)$。

平均秩表达“证据不足以区分”，稳定规则则便于生成严格列表。课程项目可选择其中一种，但应在所有算法中一致处理，且保存该选择。如果只有输出文件的存储顺序改变，就导致最终评价改变，通常意味着某处把非确定遍历顺序当成了排序规则。稳定结果不仅方便复现，也能避免把微小随机波动误解释为参数差异。

11 一个完整的人工评价演练

11.1 从名次变化计算指标变化

为检查评价定义，另构造一个与真实语料无关的查询。设其相关文档恰好为 A 和 C，单路前四项依次为 B、A、D、C，融合结果为 A、B、C、D。所有文档均已有判断，且只有 A、C 相关。单路的 AP 为

$$\text{AP}_{\text{single}} = \frac{1}{2}\left(\frac{1}{2} + \frac{2}{4}\right) = 0.5, \tag{22}$$

而融合 AP 为

$$\text{AP}_{\text{fused}} = \frac{1}{2}\left(1 + \frac{2}{3}\right) = \frac{5}{6}. \tag{23}$$

Recall@4 在两者中均为 1；Recall@2 也均为 1/2。这些召回指标不变，不代表排序没有改善，而是它们只检查在截止位置前覆盖了多少相关文档，不衡量相关文档在窗口内的具体次序。

采用二值 gain 并取 $K = 3$，单路的 DCG 为 $1/\log_2 3$，融合为 $1 + 1/\log_2 4 = 1.5$。理想排序为 A、C、B，因此

$$\mathrm{IDCG}\,@3 = 1 + \frac{1}{\log_2 3}, \tag{24}$$

$$\mathrm{nDCG}_{\mathrm{single}}\,@3 \approx 0.3869, \tag{25}$$

$$\mathrm{nDCG}_{\mathrm{fused}}\,@3 \approx 0.9197. \tag{26}$$

这些数值是由人工构造名单直接计算的演练，不是本文项目在公开数据上的成绩。它们的作用是提供一个可手动审计的评价器输入与预期输出。

11.2 为什么只报告最终得分不够

如果只看到 MAP 从 0.5 变成 5/6，无法知道改善来自检索了新文档还是重新排列了原候选。在此演练中，候选集完全一致，只改变次序，所以可把收益归于重排。真实项目必须同时保存候选与排序，才能作出同样清楚的归因。

进一步，如果 C 在官方 qrels 中未被判断而按 0 计，则该演练的可观察相关集合发生变化，指标也会不同。算法可能未变，评价依据却变了。因而运行结果文件和 qrels 版本应共同构成一个评价单元；共享某个分数但不共享判断文件与指标定义，无法构成完整复现。

11.3 聚合后的平均值可能如何误导

设两个查询的 nDCG 变化分别为 +0.4 与 −0.3，宏平均提升 0.05。若第一个查询每天只出现一次，第二个查询每天出现一百次，真实访问加权变化则约为 −0.293。课程数据集通常采用查询等权，是合理且可重复的基准约定；但它与生产访问分布不是同一个目标。

这不要求在课程报告中虚构真实访问量，而是要求写清评价对象。可以说“在测试查询等权条件下提高平均质量”，不宜直接说“所有用户体验改善”。若将来有真实访问日志，还需考虑隐私、查询重复、时效与流量偏差，另行设计权重和评估流程。

11.4 预注册式记录能减少解释自由度

在运行前写下主要指标、基线、参数网格、查询划分与失败处理，是一种低成本的自我约束。例如主要指标定为 nDCG@10，Recall@100 和 MAP 作为辅助；选择验证集主要指标最高的配置，若相同则优先更小候选深度，再优先更简单参数。这样可以避免在看到结果后临时更换指标，让一组偶然改善成为主要发现。

报告仍可以展示探索性发现，但应把预先计划与事后分析分开。若某个查询类别在结果出现后才被识别出来，就应称为探索性案例，而不是已经独立证实的泛化规律。严格限制表述范围不会削弱项目，反而使读者能够准确判断证据的强弱。

12 结语：如何形成可辩护的阅读结论

RRF 值得学习，不仅因为公式简短，更因为它展示了一种明确的工程取舍：用序位证据换取对任意计分尺度的独立性。本文的自主构造说明，参数能够改变排名，候选截断能够改变证据，重复来源能够改变隐含权重，而忽略分数也会忽略有价值的间距信息。这些性质共同决定了它应被当作需要评价的基线，而不是默认正确的答案。

对课程学习而言，最有意义的工作是把可解释公式、反例和可复现评价连接起来。三篇材料分别帮助提出算法、限制推广范围和设计外部检验；项目则需要用独立的真实运行证据完成最后一步。本文已完成的是阅读与分析，关于具体语料上的效果、延迟和最优参数，须由项目实测后再作判断。

AI 辅助说明. 本文使用 AI 辅助检索文献、推导检查与组织表达。参考文献和引用数据均标明来源；构造案例不作为真实实验。提交者应核对全文、理解公式和局限，并据实际完成的实验补充说明后署名。

REFERENCES

[1] Sebastian Bruch, Siyu Gai, and Amir Ingber. 2023. An Analysis of Fusion Functions for Hybrid Retrieval. arXiv:2210.11934 [cs.IR] https://arxiv.org/abs/2210.11934v2 Version 2, 4 May 2023; related journal DOI: 10.1145/3596512.

[2] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Büttcher. 2009. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '09)*. ACM, 758–759. https://doi.org/10.1145/1571941.1572114

[3] Nandan Thakur, Nils Reimers, Andreas Rücklé, Abhishek Srivastava, and Iryna Gurevych. 2021. BEIR: A Heterogenous Benchmark for Zero-shot Evaluation of Information Retrieval Models. In *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks*, Vol. 1. https://arxiv.org/abs/2104.08663